

Aprendizaje de Máquina

Sesión 3: Flujo de un proyecto de Machine Learning

Angel Rodríguez



Avisos

- ▶ ¡Ya llegó el libro!
- ▶ Anuncio y la liga en blackboard.

<https://research-ebsco-com.udlap.idm.oclc.org/plink/0bc248dc-1ced-32f8-a529-0a165bb8feaa>

Actividad

Vamos a suponer que nos contrataron para un proyecto en una compañía de bienes raíces. Vamos a realizar 8 pasos:

1. Entender el problema
2. Conseguir los datos
3. Explorar y visualizar los datos
4. Preparar los datos
5. Seleccionar un modelo y entrenarlo
6. Afinar el modelo
7. Presentar la solución
8. Lanzar, monitorear y mantener el sistema

2. Conseguir los datos

- ▶ `https://hom1.info/colab-p`

3. Explorar y visualizar los datos

Viendo los histogramas:

- ▶ La ganancia media no está en USD. La normalizaron para que vaya de 0.5 a 15.
- ▶ Valor y edad de alojamiento están "truncados".
Principalmente el valor es el más importante, **¿porqué?**
 - ▶ Se puede pedir que se vuelva a recolectar la información.
 - ▶ Eliminar esos distritos del conjunto de entrenamiento y de prueba.
- ▶ Todos los atributos tienen diferentes escalas.
- ▶ Los histogramas están sesgados a la derecha.

4. Preparar los datos

Interfaz y diseño de Scikit-Learn:

- ▶ *Consistencia*: Todos los objetos comparten una interfaz simple y consistente:
 - ▶ *Estimadores*: Cualquier objeto que pueda estimar parámetros basado en un dataset es llamado un *estimador*. La estimación se llama con el método `fit()`, que tiene como entrada un dataset (o dos, si hay etiquetas). Cualquier otro parámetro necesario es considerado un hiperparámetro.

4. Preparar los datos

- ▶ *Consistencia:*

- ▶ *Estimadores:*

- ▶ *Transformadores:* Los estimadores que además pueden transformar un dataset se llaman *transformadores*. La estructura es simple: se utiliza el método `transform()`, con el data set a transformar como entrada. Regresa el dataset transformado. Normalmente utiliza parámetros aprendidos. Todos los transformers también tienen el método `fit_transform()`, que es equivalente (pero posiblemente más rápido) a aplicar `fit()` y luego `transform()`.
 - ▶ *Predictor:* Los estimadores son capaces de hacer predicciones dado un dataset son llamados *predictors*. Por ejemplo, `LinearRegression`. Un predictor tiene el método `predict()`, que tiene como entrada un nuevo dataset y nos regresa otro dataset con las predicciones. También cuenta con un método `score`, que mide la calidad de la predicción dado un conjunto de prueba.

4. Preparar los datos

- ▶ *Consistencia*
- ▶ Inspección:
 - ▶ Todos los parámetros de los estimadores son accesibles directamente como `estimador.parámetro` (ejemplo `imputer.strategy`), y los parámetros aprendidos son accesibles vía `estimador.parámetroAprendido_`.
- ▶ Clases:
 - ▶ Datasets están representados como arreglos de NumPy (pero también acepta dataframes de Pandas¹). Hyperparámetros son cadenas o números normales de Python.
- ▶ Valores por default:
 - ▶ Scikit-learn provee con valores default para la mayoría de los parámetros, facilitando la creación rápida de un sistema funcional base.

¹ `sklearn.set_config(transform_output="pandas")` para que la salida sea dataframe

5. Seleccionar un modelo y entrenarlo

6. Afinar el modelo

7. Presentar la solución

8. Lanzar, monitorear y mantener el sistema

Actividad

Acordeón de los 8 pasos:

1. Entender el problema
2. Conseguir los datos
3. Explorar y visualizar los datos
4. Preparar los datos
5. Seleccionar un modelo y entrenarlo
6. Afinar el modelo
7. Presentar la solución
8. Lanzar, monitorear y mantener el sistema

1. Plantear el problema y ver el panorama general

- ▶ Define el objetivo en términos de negocio.
- ▶ Aclara cómo se usará la solución.
- ▶ Identifica soluciones actuales o atajos existentes.
- ▶ Decide cómo encuadrar el problema: supervisado/no supervisado, online/offline, etc.
- ▶ Define cómo se medirá el desempeño.
- ▶ Verifica que la métrica esté alineada con el objetivo de negocio.
- ▶ Establece el desempeño mínimo necesario para lograr el objetivo.
- ▶ Busca problemas comparables y herramientas reutilizables.
- ▶ Confirma si hay experiencia humana disponible.
- ▶ Describe cómo resolverías el problema manualmente.
- ▶ Lista los supuestos propios y de otras personas.
- ▶ Valida los supuestos siempre que sea posible.

2. Obtener los datos

Automatiza tanto como sea posible para poder obtener datos frescos fácilmente.

- ▶ Lista los datos necesarios y en qué cantidad.
- ▶ Encuentra y documenta de dónde obtenerlos.
- ▶ Estima cuánto espacio ocuparán.
- ▶ Revisa obligaciones legales y consigue autorización si hace falta.
- ▶ Obtén permisos de acceso.
- ▶ Crea un espacio de trabajo con almacenamiento suficiente.
- ▶ Descarga o recopila los datos.
- ▶ Convierte los datos a un formato manipulable sin alterar su contenido.
- ▶ Elimina o protege información sensible; por ejemplo, anonimízala.
- ▶ Revisa tamaño y tipo: series de tiempo, muestra, geográficos, etc.
- ▶ Separa un conjunto de prueba y nunca lo mires: evita el *data snooping*.

3. Explorar los datos para obtener insights

Intenta obtener insights de una persona experta en el dominio.

- ▶ Crea una copia para exploración; muestrea si es necesario.
- ▶ Usa un notebook para registrar la exploración.
- ▶ Estudia cada atributo:
 - ▶ nombre y tipo;
 - ▶ porcentaje de valores faltantes;
 - ▶ ruido, outliers o errores de redondeo;
 - ▶ utilidad potencial para la tarea;
 - ▶ distribución: gaussiana, uniforme, logarítmica, etc.
- ▶ En aprendizaje supervisado, identifica el/los atributos objetivo.
- ▶ Visualiza los datos.
- ▶ Estudia correlaciones entre atributos.
- ▶ Revisa cómo resolverías el problema manualmente.
- ▶ Identifica transformaciones prometedoras.
- ▶ Detecta datos extra que serían útiles; si hace falta, vuelve a obtener datos.
- ▶ Documenta lo aprendido.

4. Preparar los datos para exponer mejor los patrones

Trabaja sobre copias y conserva intacto el dataset original. Escribe funciones para todas las transformaciones: reutilizarlas, aplicarlas a datos nuevos y tratarlas como hiperparámetros será mucho más fácil.

Limpieza y selección

- ▶ Corrige o elimina outliers, si conviene.
- ▶ Rellena valores faltantes con cero, media, mediana, etc.; o elimina filas/columnas.
- ▶ Elimina atributos que no aportan información útil para la tarea.

Ingeniería de características

- ▶ Discretiza variables continuas cuando sea útil.
- ▶ Descompón variables: categorías, fecha/hora, texto, etc.

Transformaciones y escalado

- ▶ Agrega transformaciones prometedoras: $\log(x)$, $\sqrt{x}$, x^2 , etc.
- ▶ Combina o agrega atributos para crear nuevas variables.
- ▶ Estandariza o normaliza las características.

Diseño reproducible

- ▶ Prepara fácilmente nuevos datasets frescos.
- ▶ Limpia de forma consistente el set de prueba y nuevas instancias.
- ▶ Reutiliza transformaciones en proyectos futuros.

5. Explorar muchos modelos y preseleccionar los mejores

Si los datos son enormes, entrena con muestras más pequeñas para probar muchos modelos, sabiendo que esto puede penalizar modelos complejos. Automatiza todo lo posible.

- ▶ Entrena modelos rápidos de varias familias: lineales, naive Bayes, SVM, Random Forests, redes neuronales, etc.
- ▶ Usa parámetros estándar al inicio.
- ▶ Mide y compara desempeño.
- ▶ Para cada modelo, usa validación cruzada N-fold y calcula media y desviación estándar.
- ▶ Analiza variables importantes para cada algoritmo.
- ▶ Estudia los tipos de errores que cometen los modelos.
- ▶ Pregunta qué datos habría usado una persona para evitar esos errores.
- ▶ Haz una ronda rápida de selección e ingeniería de características.
- ▶ Itera una o dos veces.
- ▶ Preselecciona los tres a cinco modelos más prometedores, idealmente con errores distintos.

6. Afinar modelos y combinarlos en una gran solución

Usa la mayor cantidad de datos posible en esta etapa, especialmente al final del afinamiento. Automatiza cuando puedas.

Afinamiento

- ▶ Ajusta hiperparámetros con validación cruzada.
- ▶ Trata las decisiones de transformación como hiperparámetros, sobre todo si no estás seguro: imputar con cero, mediana o eliminar filas.
- ▶ Si hay muchos valores, prefiere búsqueda aleatoria sobre grid search.
- ▶ Si entrenar tarda mucho, considera optimización bayesiana.

Ensamble y evaluación final

- ▶ Prueba métodos de ensamble: combinar buenos modelos suele superar a cada modelo individual.
- ▶ Cuando confíes en el modelo final, mide el desempeño en el conjunto de prueba.
- ▶ Estima el error de generalización.
- ▶ No ajustes el modelo después de medir el error de generalización: sobreajustarías el conjunto de prueba.

7. Presentar la solución

- ▶ Documenta lo que hiciste.
- ▶ Crea una presentación clara y atractiva.
- ▶ Empieza destacando el panorama general.
- ▶ Explica por qué la solución cumple el objetivo de negocio.
- ▶ Presenta hallazgos interesantes del proceso.
- ▶ Describe qué funcionó y qué no funcionó.
- ▶ Enumera supuestos y limitaciones del sistema.
- ▶ Comunica hallazgos clave con visualizaciones memorables o frases fáciles de recordar.

8. Lanzar, monitorear y mantener el sistema

Lanzamiento

- ▶ Prepara la solución para producción.
- ▶ Conéctala a las entradas de datos productivas.
- ▶ Escribe pruebas unitarias y verificaciones operativas.

Monitoreo

- ▶ Crea código para revisar desempeño en vivo a intervalos regulares.
- ▶ Dispara alertas cuando el desempeño caiga.

Mantenimiento

- ▶ Vigila degradación lenta: los modelos se deterioran conforme evolucionan los datos.
- ▶ Considera que medir desempeño puede requerir revisión humana o crowdsourcing.
- ▶ Monitorea también la calidad de las entradas: sensores fallando, datos obsoletos de otro equipo, etc.
- ▶ Reentrena modelos regularmente con datos frescos y automatiza tanto como sea posible.

¡Gracias!