

Aprendizaje de Máquina

Sesión 7: Teoría del aprendizaje

Angel Rodríguez

TALLERES CMAT

UDLAP®

A circular portrait of a man with a beard and mustache, wearing a dark suit jacket over a light-colored shirt. He has his arms crossed and is standing outdoors in front of a green plant and a tree. The image is framed by a thick orange border.

 Dr. Marco Antonio Pérez-de la Rosa

Maldición de la dimensionalidad

- ▶ Ejemplo cajas para predecir un nuevo punto.
- ▶ Ejemplo regresión polinomial.
- ▶ Ejemplo volumen de una esfera contenido entre el radio $r = 1$ y $r = 1 - \epsilon$.

El problema central

La teoría de decisión conecta un modelo probabilístico con una acción.



Pregunta central

Dadas las probabilidades de las posibles clases,

$$p(C_k | \mathbf{x}),$$

¿qué acción debemos tomar?

Ejemplo: diagnóstico médico

Supongamos que un modelo obtiene

$$p(C_1 = \text{cáncer} \mid \mathbf{x}) = 0,08,$$

$$p(C_2 = \text{no cáncer} \mid \mathbf{x}) = 0,87,$$

y existe además un 0,05 de probabilidad asociado a un resultado inconcluso.

Podríamos considerar dos acciones:

Acción A

Mandar al paciente a casa.

Acción B

Solicitar una prueba adicional o biopsia.


Aunque “no cáncer” sea mucho más probable, el costo de **no detectar un cáncer real** podría ser mucho mayor.

Regiones de decisión

Una regla de clasificación divide el espacio de entrada en regiones:

$$R_1, R_2, \dots, R_K.$$

Si $\mathbf{x} \in R_k$, entonces decidimos la clase C_k .



Minimizar la tasa de clasificación errónea

Supongamos inicialmente que **todos los errores cuestan lo mismo**.

La probabilidad de equivocarnos cuando tenemos dos clase es de

Minimizar la tasa de clasificación errónea

Supongamos inicialmente que **todos los errores cuestan lo mismo**.

La probabilidad de equivocarnos cuando tenemos dos clase es de

$$p(\text{error}) = p(\mathbf{x} \in R_1, C_2) + p(\mathbf{x} \in R_2, C_1) =$$

Minimizar la tasa de clasificación errónea

Supongamos inicialmente que **todos los errores cuestan lo mismo**.

La probabilidad de equivocarnos cuando tenemos dos clase es de

$$p(\text{error}) = p(\mathbf{x} \in R_1, C_2) + p(\mathbf{x} \in R_2, C_1) =$$

$$p(\text{error}) = \int_{R_1} p(\mathbf{x}, C_2) + \int_{R_2} p(\mathbf{x}, C_1).$$

Supongamos que $p(\mathbf{x}, C_1) > p(\mathbf{x}, C_2)$ para un valor dado de $\mathbf{x}$.
¿Cómo asignamos un $\mathbf{x}$ a una región para minimizar $p(\text{error})$?

Minimizar la tasa de clasificación errónea

En general, sabemos que $p(\mathbf{x}, C_k) = p(C_k|\mathbf{x})p(\mathbf{x})$. Ambos tienen en común $p(\mathbf{x})$, entonces asignamos $\mathbf{x}$ a:

$$k^* = \arg \max_k p(C_k | \mathbf{x})$$

Es decir:

Elegimos la clase con mayor probabilidad posterior.

Pérdida 0–1

En el caso anterior fue la regla de decisión de Bayes cuando utilizamos **pérdida 0–1**. Podemos definir la **función de pérdida**

$$L_{ki} = \begin{cases} 0, & k = i, \\ 1, & k \neq i. \end{cases}$$

donde

- ▶ k indica la clase verdadera;
- ▶ i indica la clase que decidimos predecir.

La matriz de pérdidas para dos clases es $L = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$.

Interpretación

Todos los errores tienen exactamente el mismo costo.

Por eso, en este caso, minimizar pérdida equivale a escoger la clase más probable.

Cuando los errores cuestan distinto

En muchos problemas los errores **no tienen el mismo costo**.
Por ejemplo:

	decir C_1	decir C_2
real C_1	0	100
real C_2	1	0

Aquí confundir C_1 con C_2 cuesta mucho más que el error contrario.

Supongamos que, para un nuevo $\mathbf{x}$, que es clase C_k , decimos que es clase C_j . Entonces, decimos que tenemos una pérdida L_{kj} , que puede ser interpretado como la entrada (k, j) de una matriz de pérdida.

Cuando los errores cuestan distinto

La solución óptima es aquella que minimiza la función de pérdida. Sin embargo depende de la clasificación real, que no sabemos. Podemos expresar la pérdida esperada:

$$\mathbb{E}[L] = \sum_k \sum_j \int_{R_j} L_{k,j} p(\mathbf{x}, C_k) d\mathbf{x}$$

Cada $\mathbf{x}$ puede ser asignada a una región R_j . Necesitamos elegir regiones R_j que minimicen la pérdida esperada, lo cual implica que para cada $\mathbf{x}$, hay que minimizar $\sum_k L_{k,j} p(\mathbf{x}, C_k)$. Usando la regla del producto $p(\mathbf{x}, C_k) = p(C_k|\mathbf{x})p(\mathbf{x})$, definimos el **riesgo condicional**

$$R(\alpha_j | \mathbf{x}) = \sum_k L_{kj} p(C_k | \mathbf{x})$$

que representa el **costo esperado** de tomar la acción α_j .

Ejemplo numérico de pérdida esperada

Supongamos que

$$p(C_1 | \mathbf{x}) = 0,20, \quad p(C_2 | \mathbf{x}) = 0,80.$$

y que las pérdidas son

	α_1 : decir C_1	α_2 : decir C_2
C_1	0	20
C_2	1	0

Entonces:

$$R(\alpha_1 | \mathbf{x}) = 0(0,20) + 1(0,80) = 0,8,$$

mientras que

$$R(\alpha_2 | \mathbf{x}) = 20(0,20) + 0(0,80) = 4.$$

Por lo tanto, **elegimos** C_1 , a pesar de que

$$p(C_2 | \mathbf{x}) > p(C_1 | \mathbf{x}).$$

Probabilidad máxima vs. pérdida mínima

El ejemplo anterior muestra una distinción fundamental.

Máxima probabilidad

Si solamente usamos

$$\arg \max_k p(C_k | \mathbf{x}),$$

predeciríamos

C_2 .

Mínima pérdida

Si consideramos los costos,

$$\arg \min_i R(\alpha_i | \mathbf{x}),$$

predecimos

C_1 .

La clase más probable no tiene que coincidir con la acción óptima.

La opción de rechazo

A veces la mejor decisión es **no tomar una decisión**.
Podemos clasificar solamente cuando


$$\max_k p(C_k | \mathbf{x}) \geq \theta$$

para algún umbral θ .

Si

$$\max_k p(C_k | \mathbf{x}) < \theta,$$

rechazamos la clasificación.



La opción de rechazo

¿Qué significa “rechazar”? Dependiendo del problema puede significar:

- ▶ solicitar más información;
- ▶ repetir una medición;
- ▶ utilizar otro modelo;
- ▶ pedir intervención humana.

Inferencia y decisión: tres estrategias

Hay tres formas generales de resolver un problema de clasificación:

1. Modelo generativo

Aprender

$$p(\mathbf{x}, C_k) = p(\mathbf{x} \mid C_k)p(C_k)$$

y después obtener el posterior mediante Bayes:

$$p(C_k \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid C_k)p(C_k)}{p(\mathbf{x})}.$$

2. Modelo discriminativo probabilístico

Aprender directamente

$$p(C_k | \mathbf{x}).$$

2. Modelo discriminativo probabilístico

Aprender directamente

$$p(C_k | \mathbf{x}).$$

3. Función discriminante

Aprender directamente una función

$$y = f(\mathbf{x})$$

que produzca la decisión.

Generativo vs. discriminativo

Un modelo probabilístico tiene una ventaja importante:

podemos cambiar la función de pérdida sin reentrenar el modelo.

Si únicamente aprendemos una frontera de decisión, cambiar los costos puede requerir modificar o volver a entrenar el clasificador.

Clasificadores probabilísticos vs. discriminantes

Modelo probabilístico

Produce

$$p(C_k | \mathbf{x}).$$

Ventajas:

- ▶ representa incertidumbre;
- ▶ permite cambiar costos;
- ▶ permite implementar rechazo;
- ▶ puede combinarse con otras fuentes de información.

Decisión directa

Produce

$$y = f(\mathbf{x}).$$

Ventajas:

- ▶ puede ser más simple;
- ▶ evita modelar probabilidades completas;
- ▶ puede ser suficiente si solamente importa clasificar.

Regresión: ahora la salida es continua

En regresión ya no queremos seleccionar una clase.
Queremos seleccionar un valor

$$y(\mathbf{x}).$$

Tenemos una distribución predictiva

$$p(t \mid \mathbf{x}),$$

donde t representa el valor real que queremos predecir.

La decisión se obtiene minimizando la pérdida esperada:

$$\mathbb{E}[L] = \iint L(t, y(\mathbf{x})) p(\mathbf{x}, t) d\mathbf{x} dt$$

Pérdida cuadrática

Consideremos la pérdida cuadrática:

$$L(t, y(\mathbf{x})) = (y(\mathbf{x}) - t)^2.$$

Queremos minimizar

$$\mathbb{E}[L] = \iint (y(\mathbf{x}) - t)^2 p(\mathbf{x}, t) d\mathbf{x} dt.$$

Al minimizar con respecto a $y(\mathbf{x})$, obtenemos

Pérdida cuadrática

Consideremos la pérdida cuadrática:

$$L(t, y(\mathbf{x})) = (y(\mathbf{x}) - t)^2.$$

Queremos minimizar

$$\mathbb{E}[L] = \iint (y(\mathbf{x}) - t)^2 p(\mathbf{x}, t) d\mathbf{x} dt.$$

Al minimizar con respecto a $y(\mathbf{x})$, obtenemos

$$y(\mathbf{x}) = \mathbb{E}[t \mid \mathbf{x}]$$

es decir,

$$y(\mathbf{x}) = \int t p(t \mid \mathbf{x}) dt.$$

Resultado

Con pérdida cuadrática, la predicción óptima es la **media condicional**.

¿Por qué aparece la media condicional?

Para un $\mathbf{x}$ fijo queremos minimizar

$$R(y | \mathbf{x}) = \int (y - t)^2 p(t | \mathbf{x}) dt.$$

Derivamos con respecto a y :

$$\frac{\partial R}{\partial y} = 2 \int (y - t) p(t | \mathbf{x}) dt.$$

En el mínimo, $\frac{\partial R}{\partial y} = 0$. Entonces

$$y \int p(t | \mathbf{x}) dt = \int t p(t | \mathbf{x}) dt.$$

Como

$$\int p(t | \mathbf{x}) dt = 1,$$

obtenemos

$$y(\mathbf{x}) = \mathbb{E}[t | \mathbf{x}].$$

Distintas pérdidas, distintas predicciones

La “mejor” predicción depende de lo que entendamos por **error**.

Pérdida	Predicción óptima	Interpretación
$(y - t)^2$	Media condicional	Penaliza errores grandes
$ y - t $	Mediana condicional	Más robusta a extremos
Pérdida tipo 0–1	Moda condicional	Valor más probable


No basta con preguntar, “¿qué modelo estoy utilizando?”, sino también debemos preguntar “¿qué función de pérdida estoy minimizando?”

Distribuciones multimodales: la media puede engañar

Supongamos que

$$p(t | \mathbf{x})$$

tiene dos modos.



La media puede encontrarse en una región donde $p(t | \mathbf{x})$ es relativamente pequeña.

Actividad 3

Supongamos

$$p(C_1 | \mathbf{x}) = 0,30, \quad p(C_2 | \mathbf{x}) = 0,70.$$

y la matriz de pérdidas

	decir C_1	decir C_2
real C_1	0	5
real C_2	1	0

Calcula:

1. $R(\text{decir } C_1 | \mathbf{x})$.
2. $R(\text{decir } C_2 | \mathbf{x})$.
3. ¿Qué acción deberíamos elegir?
4. ¿Qué decisión obtendríamos si todos los errores tuvieran costo 1?

Actividad 3: solución

Actividad: Proyecto final paso 0

Seleccionar el problema y conjunto de datos

- ▶ Formen equipos: parejas y un equipo de 3 integrantes.
- ▶ Seleccionen un concurso de **Kaggle Competitions**.
- ▶ Entreguen un PDF breve con:
 - ▶ nombres de los integrantes;
 - ▶ nombre y liga del concurso;
 - ▶ descripción del problema;
 - ▶ tipo de problema: clasificación o regresión;
 - ▶ variable objetivo (*target*);
 - ▶ descripción breve del conjunto de datos;
 - ▶ justificación de la elección.

Importante En esta etapa no es necesario entrenar modelos ni realizar análisis exploratorio.

Fecha de entrega: Martes 15 de septiembre de 2026, 11:59 p.m.

¡Gracias!