

Aprendizaje de Máquina

Sesión 6: Teoría del aprendizaje

Angel Rodríguez

Actividad

Acordeón de los 8 pasos (útil para su **proyecto final**).

1. Entender el problema
2. Conseguir los datos
3. Explorar y visualizar los datos
4. Preparar los datos
5. Seleccionar un modelo y entrenarlo
6. Afinar el modelo
7. Presentar la solución
8. Lanzar, monitorear y mantener el sistema

1. Plantear el problema y ver el panorama general

- ▶ Define el objetivo en términos de negocio.
- ▶ Aclara cómo se usará la solución.
- ▶ Identifica soluciones actuales o atajos existentes.
- ▶ Decide cómo encuadrar el problema: supervisado/no supervisado, online/offline, etc.
- ▶ Define cómo se medirá el desempeño.
- ▶ Verifica que la métrica esté alineada con el objetivo de negocio.
- ▶ Establece el desempeño mínimo necesario para lograr el objetivo.
- ▶ Busca problemas comparables y herramientas reutilizables.
- ▶ Confirma si hay experiencia humana disponible.
- ▶ Describe cómo resolverías el problema manualmente.
- ▶ Lista los supuestos propios y de otras personas.
- ▶ Valida los supuestos siempre que sea posible.

2. Obtener los datos

Automatiza tanto como sea posible para poder obtener datos frescos fácilmente.

- ▶ Lista los datos necesarios y en qué cantidad.
- ▶ Encuentra y documenta de dónde obtenerlos.
- ▶ Estima cuánto espacio ocuparán.
- ▶ Revisa obligaciones legales y consigue autorización si hace falta.
- ▶ Obtén permisos de acceso.
- ▶ Crea un espacio de trabajo con almacenamiento suficiente.
- ▶ Descarga o recopila los datos.
- ▶ Convierte los datos a un formato manipulable sin alterar su contenido.
- ▶ Elimina o protege información sensible; por ejemplo, anonimízala.
- ▶ Revisa tamaño y tipo: series de tiempo, muestra, geográficos, etc.
- ▶ Separa un conjunto de prueba y nunca lo mires: evita el *data snooping*.

3. Explorar los datos para obtener insights

Intenta obtener insights de una persona experta en el dominio.

- ▶ Crea una copia para exploración; muestrea si es necesario.
- ▶ Usa un notebook para registrar la exploración.
- ▶ Estudia cada atributo:
 - ▶ nombre y tipo;
 - ▶ porcentaje de valores faltantes;
 - ▶ ruido, outliers o errores de redondeo;
 - ▶ utilidad potencial para la tarea;
 - ▶ distribución: gaussiana, uniforme, logarítmica, etc.
- ▶ En aprendizaje supervisado, identifica el/los atributos objetivo.
- ▶ Visualiza los datos.
- ▶ Estudia correlaciones entre atributos.
- ▶ Revisa cómo resolverías el problema manualmente.
- ▶ Identifica transformaciones prometedoras.
- ▶ Detecta datos extra que serían útiles; si hace falta, vuelve a obtener datos.
- ▶ Documenta lo aprendido.

4. Preparar los datos para exponer mejor los patrones

Trabaja sobre copias y conserva intacto el dataset original. Escribe funciones para todas las transformaciones: reutilizarlas, aplicarlas a datos nuevos y tratarlas como hiperparámetros será mucho más fácil.

Limpieza y selección

- ▶ Corrige o elimina outliers, si conviene.
- ▶ Rellena valores faltantes con cero, media, mediana, etc.; o elimina filas/columnas.
- ▶ Elimina atributos que no aportan información útil para la tarea.

Ingeniería de características

- ▶ Discretiza variables continuas cuando sea útil.
- ▶ Descompón variables: categorías, fecha/hora, texto, etc.

Transformaciones y escalado

- ▶ Agrega transformaciones prometedoras: $\log(x)$, $\sqrt{x}$, x^2 , etc.
- ▶ Combina o agrega atributos para crear nuevas variables.
- ▶ Estandariza o normaliza las características.

Diseño reproducible

- ▶ Prepara fácilmente nuevos datasets frescos.
- ▶ Limpia de forma consistente el set de prueba y nuevas instancias.
- ▶ Reutiliza transformaciones en proyectos futuros.

5. Explorar muchos modelos y preseleccionar los mejores

Si los datos son enormes, entrena con muestras más pequeñas para probar muchos modelos, sabiendo que esto puede penalizar modelos complejos. Automatiza todo lo posible.

- ▶ Entrena modelos rápidos de varias familias: lineales, naive Bayes, SVM, Random Forests, redes neuronales, etc.
- ▶ Usa parámetros estándar al inicio.
- ▶ Mide y compara desempeño.
- ▶ Para cada modelo, usa validación cruzada N-fold y calcula media y desviación estándar.
- ▶ Analiza variables importantes para cada algoritmo.
- ▶ Estudia los tipos de errores que cometen los modelos.
- ▶ Pregunta qué datos habría usado una persona para evitar esos errores.
- ▶ Haz una ronda rápida de selección e ingeniería de características.
- ▶ Itera una o dos veces.
- ▶ Preselecciona los tres a cinco modelos más prometedores, idealmente con errores distintos.

6. Afinar modelos y combinarlos en una gran solución

Usa la mayor cantidad de datos posible en esta etapa, especialmente al final del afinamiento. Automatiza cuando puedas.

Afinamiento

- ▶ Ajusta hiperparámetros con validación cruzada.
- ▶ Trata las decisiones de transformación como hiperparámetros, sobre todo si no estás seguro: imputar con cero, mediana o eliminar filas.
- ▶ Si hay muchos valores, prefiere búsqueda aleatoria sobre grid search.
- ▶ Si entrenar tarda mucho, considera optimización bayesiana.

Ensamble y evaluación final

- ▶ Prueba métodos de ensamble: combinar buenos modelos suele superar a cada modelo individual.
- ▶ Cuando confíes en el modelo final, mide el desempeño en el conjunto de prueba.
- ▶ Estima el error de generalización.
- ▶ No ajustes el modelo después de medir el error de generalización: sobreajustarías el conjunto de prueba.

7. Presentar la solución

- ▶ Documenta lo que hiciste.
- ▶ Crea una presentación clara y atractiva.
- ▶ Empieza destacando el panorama general.
- ▶ Explica por qué la solución cumple el objetivo de negocio.
- ▶ Presenta hallazgos interesantes del proceso.
- ▶ Describe qué funcionó y qué no funcionó.
- ▶ Enumera supuestos y limitaciones del sistema.
- ▶ Comunica hallazgos clave con visualizaciones memorables o frases fáciles de recordar.

8. Lanzar, monitorear y mantener el sistema

Lanzamiento

- ▶ Prepara la solución para producción.
- ▶ Conéctala a las entradas de datos productivas.
- ▶ Escribe pruebas unitarias y verificaciones operativas.

Monitoreo

- ▶ Crea código para revisar desempeño en vivo a intervalos regulares.
- ▶ Dispara alertas cuando el desempeño caiga.


Mantenimiento

- ▶ Vigila degradación lenta: los modelos se deterioran conforme evolucionan los datos.
- ▶ Considera que medir desempeño puede requerir revisión humana o crowdsourcing.
- ▶ Monitorea también la calidad de las entradas: sensores fallando, datos obsoletos de otro equipo, etc.
- ▶ Reentrena modelos regularmente con datos frescos y automatiza tanto como sea posible.

Ejemplo: Ajuste (o regresión) polinomial.

Motivación en aprendizaje de máquina





En problemas reales, los datos son finitos y suelen estar contaminados con ruido. Por eso, para una entrada $\mathbf{x}$ no siempre existe una respuesta t perfectamente determinada.



- ▶ Tenemos N observaciones:
 $\mathbf{x} = (x_1, \dots, x_N)^\top$, con sus valores
 $\mathbf{t} = (t_1, \dots, t_N)^\top$.
- ▶ Ajustar los datos con polinomio:
 $y(x, \mathbf{w}) = w_0 + \dots + w_M x^M$.
- ▶ M es el grado del polinomio y elige el modelo. $\mathbf{w}$ es el vector de coeficientes.


Ajuste polinomial de curvas

- Como no queremos hacerlo perfecto (interpolación), vamos a minimizar el error: $E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(x_n, \mathbf{w}) - t_n)^2$





Error

Si nos llegan nuevos datos y probamos, podemos esperar algo así:



	$M = 0$	$M = 1$	$M = 6$	$M = 9$
w_0^*	0.19	0.82	0.31	0.35
w_1^*		-1.27	7.99	232.37
w_2^*			-25.43	-5321.83
w_3^*			17.37	48568.31
w_4^*				-231639.30
w_5^*				640042.26
w_6^*				-1061800.52
w_7^*				1042400.18
w_8^*				-557682.99
w_9^*				125201.43



Usemos más datos



Otra alternativa


Actualizar el error:

$$\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (y(x_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (1)$$



Valores de λ

	$\ln \lambda = -\infty$	$\ln \lambda = -18$	$\ln \lambda = 0$
w_0^*	0.35	0.35	0.13
w_1^*	232.37	4.74	-0.05
w_2^*	-5321.83	-0.77	-0.06
w_3^*	48568.31	-31.97	-0.05
w_4^*	-231639.30	-3.89	-0.03
w_5^*	640042.26	55.28	-0.02
w_6^*	-1061800.52	41.32	-0.01
w_7^*	1042400.18	-45.95	-0.00
w_8^*	-557682.99	-91.53	0.00
w_9^*	125201.43	72.68	0.01



Variables aleatorias discretas

Una variable aleatoria discreta puede tomar valores en un conjunto finito o numerable.

Distribución de probabilidad

$$0 \leq p(X = x_i) \leq 1, \quad \sum_i p(X = x_i) = 1.$$

Ejemplo

Si X representa el resultado de lanzar un dado justo,

$$p(X = i) = \frac{1}{6}, \quad i = 1, \dots, 6.$$

Reglas básicas: suma y producto

Sean X y Y dos variables aleatorias discretas.

Regla de la suma

$$p(X) = \sum_Y p(X, Y).$$

Sirve para eliminar una variable no observada.

Regla del producto

$$p(X, Y) = p(Y | X)p(X).$$

Descompone una probabilidad conjunta.

Estas dos reglas son la base de la inferencia probabilística.

Teorema de Bayes

A partir de la regla del producto:

$$p(X, Y) = p(Y | X)p(X) = p(X | Y)p(Y).$$

Bayes

$$p(Y | X) = \frac{p(X | Y)p(Y)}{p(X)}.$$

$$\underbrace{p(Y | X)}_{\text{posterior}} = \frac{\overbrace{p(X | Y)}^{\text{verosimilitud}} \overbrace{p(Y)}^{\text{prior}}}{\underbrace{p(X)}_{\text{normalización}}}.$$

En clasificación, Y puede representar la clase y X las características observadas.

Variables continuas y densidades

Para una variable continua x , se usa una densidad $p(x)$.

Probabilidad en un intervalo

$$p(a \leq x \leq b) = \int_a^b p(x) dx.$$

Condiciones de una densidad

$$p(x) \geq 0, \quad \int_{-\infty}^{\infty} p(x) dx = 1.$$

Cuidado

Para variables continuas, $p(x)$ no es una probabilidad puntual. La probabilidad se obtiene integrando sobre una región.

Función de distribución acumulativa

La probabilidad de que x esté en el intervalo $(-\infty, z)$ está dada por la *función de distribución acumulativa*:

$$P(z) = \int_{-\infty}^z p(x) dx \quad (2)$$

Y satisface que $P'(x) = p(x)$.

Densidad conjunta, marginal y condicional

Para variables continuas x y y :

Marginalización

$$p(x) = \int p(x, y) dy.$$

Regla del producto

$$p(x, y) = p(y | x)p(x).$$

Condicional

$$p(y | x) = \frac{p(x, y)}{p(x)}.$$

- ▶ $p(x, y)$: comportamiento conjunto.
- ▶ $p(x)$: ignoramos y .
- ▶ $p(y | x)$: distribución de y sabiendo x .

Esperanza matemática

La esperanza representa un promedio ponderado por probabilidad.

Caso discreto

$$\mathbb{E}[f(X)] = \sum_x p(x)f(x).$$

Caso continuo

$$\mathbb{E}[f(X)] = \int p(x)f(x) dx.$$

Media

Si $f(X) = X$, entonces

$$\mathbb{E}[X] = \mu.$$

Varianza y covarianza

La varianza mide dispersión alrededor de la media.

$$\text{Var}[f(x)] = \mathbb{E}[(f(x) - \mathbb{E}[f(x)])^2] = \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2.$$

En particular, si $f(x) = x$:

$$\text{Var}[X] = \mathbb{E}[(x - \mathbb{E}[x])^2] = \mathbb{E}[x^2] - \mathbb{E}[x]^2.$$

La covarianza mide cómo varían dos variables conjuntamente.

$$\text{Cov}[X, Y] = \mathbb{E}_{X,Y}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}_{X,Y}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Para vectores aleatorios $\mathbf{x}, \mathbf{y}$:

$$\text{Cov}[\mathbf{x}, \mathbf{y}] = \mathbb{E}_{\mathbf{x}, \mathbf{y}}[\mathbf{x}\mathbf{y}^T] - \mathbb{E}[\mathbf{x}]\mathbb{E}[\mathbf{y}^T].$$

Interpretación bayesiana de la probabilidad

Frecuentista

La probabilidad se interpreta como frecuencia relativa en muchas repeticiones de un experimento.

Bayesiana

La probabilidad representa un grado de creencia racional sobre una cantidad incierta.

En aprendizaje bayesiano, los parámetros también pueden tratarse como variables inciertas:

$$p(\mathbf{w} \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}.$$

En resumen: $\text{posterior} \propto \text{verosimilitud} \times \text{prior}$

La distribución Gaussiana

La distribución normal o Gaussiana es central porque modela ruido, errores de medición y muchas cantidades agregadas.

Caso unidimensional

$$\mathcal{N}(x \mid \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}.$$

- ▶ μ : media o centro de la distribución.
- ▶ σ^2 : varianza; controla la dispersión.
- ▶ σ : desviación estándar.

Gaussiana multivariada

Para $\mathbf{x} \in \mathbb{R}^D$:

Densidad multivariada

$$\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}.$$

- ▶ $\boldsymbol{\mu}$ es el vector de medias.
- ▶ $\boldsymbol{\Sigma}$ es la matriz de covarianzas de tamaño $D \times D$.
- ▶ La forma de las curvas de nivel depende de $\boldsymbol{\Sigma}$.

Máxima verosimilitud: idea

Supongamos datos independientes $\mathcal{D} = \{x_1, \dots, x_N\}$ generados por un modelo $p(x | \theta)$.

Función de Verosimilitud

$$p(\mathcal{D} | \theta) = \prod_{n=1}^N p(x_n | \theta).$$

Log-verosimilitud

$$\ln p(\mathcal{D} | \theta) = \sum_{n=1}^N \ln p(x_n | \theta).$$

El estimador de máxima verosimilitud elige el parámetro que hace más probables los datos observados.

Ajuste de curvas visto probabilísticamente

En regresión, podemos escribir el objetivo como

$$t = y(x, \mathbf{w}) + \epsilon,$$

con ruido Gaussiano

$$\epsilon \sim \mathcal{N}(0, \beta^{-1}).$$

Entonces,

$$p(t \mid x, \mathbf{w}, \beta) = \mathcal{N}(t \mid y(x, \mathbf{w}), \beta^{-1}).$$

Conexión importante

Maximizar la verosimilitud bajo ruido Gaussiano equivale a minimizar una suma de errores cuadrados.

Bayes para los parámetros del modelo

En lugar de elegir un único valor de $\mathbf{w}$, el enfoque bayesiano mantiene una distribución sobre los parámetros.

Posterior de los parámetros

$$p(\mathbf{w} \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}.$$

- ▶ El prior $p(\mathbf{w})$ expresa creencias antes de ver los datos.
- ▶ La verosimilitud $p(\mathcal{D} \mid \mathbf{w})$ mide compatibilidad con los datos.
- ▶ El posterior combina ambos elementos.

Distribución predictiva bayesiana

Para predecir un nuevo valor t dado x , no sólo usamos un parámetro puntual: promediamos sobre la incertidumbre de $\mathbf{w}$.


Predicción

$$p(t \mid x, \mathcal{D}) = \int p(t \mid x, \mathbf{w}) p(\mathbf{w} \mid \mathcal{D}) d\mathbf{w}.$$

Idea intuitiva

La predicción final combina muchas curvas posibles, ponderadas por qué tan plausibles son después de observar los datos.

Resultado final




Resumen de fórmulas clave

Concepto	Fórmula
Suma	$p(X) = \sum_Y p(X, Y)$
Producto	$p(X, Y) = p(Y X)p(X)$
Bayes	$p(Y X) = \frac{p(X Y)p(Y)}{p(X)}$
Densidad	$P(a \leq x \leq b) = \int_a^b p(x) dx$
Esperanza	$\mathbb{E}[f(X)] = \int p(x)f(x) dx$
Varianza	$\text{Var}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$
Gaussiana	$\mathcal{N}(x \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
Predictiva	$p(t x, \mathcal{D}) = \int p(t x, \mathbf{w})p(\mathbf{w} \mathcal{D}) d\mathbf{w}$


Maldición de la dimensionalidad

- ▶ Ejemplo cajas para predecir un nuevo punto.
- ▶ Ejemplo regresión polinomial.
- ▶ Ejemplo volumen de una esfera contenido entre el radio $r = 1$ y $r = 1 - \epsilon$.


Cajas para nuevo punto



Cajas para nuevo punto



Volumen de una esfera



No todo está perdido

Para aplicaciones reales:

- ▶ Los datos reales normalmente están confinados a una región del espacio que tenga dimensionalidad *efectiva* baja.
- ▶ Los datos reales normalmente tienen propiedades de suavidad localmente, lo cual permite utilizar técnicas estilo interpolación.

Teoría de decisiones.

Probabilidad no es todavía decisión: Un modelo probabilístico puede decirnos

$$p(C_k | \mathbf{x})$$

pero en una aplicación real debemos decidir qué acción tomar.

Ejemplo: $\mathbf{x}$ es una imagen de rayos-x de un paciente, y queremos predecir si C_0 no hay presencia de cáncer o C_1 sí la hay.

La teoría de decisión conecta probabilidades con acciones óptimas.

Problema típico: clasificación

Supongamos que queremos clasificar una entrada $\mathbf{x}$ en una de K clases:

$$C_1, C_2, \dots, C_K.$$

Objetivo

Dado un nuevo punto $\mathbf{x}$, elegir una clase o acción.

El modelo probabilístico nos da probabilidades posteriores:

$$p(C_k | \mathbf{x}) = \frac{p(\mathbf{x} | C_k)p(C_k)}{p(\mathbf{x})},^1 \quad k = 1, \dots, K.$$

Pero necesitamos una regla de decisión.


¹ ¿Qué significa cada término en el ejemplo de detección de cáncer?

Regiones de decisión

Una regla de clasificación divide el espacio de entrada en regiones:

$$\mathbb{R}_1, \mathbb{R}_2, \dots, \mathbb{R}_K.$$

Si $\mathbf{x} \in \mathbb{R}_k$, entonces decidimos la clase C_k .



frontera de decisión

¡Gracias!